

PROYECTO DE CIENCIA DE DATOS

Fase 1

Asociación entre las horas diarias de videojuegos y el rendimiento académico en estudiantes de 16 a 24 años

Materia: Data Science — Prof. D.Sc. Margarita Ruiz

Integrantes: José Emmanuel Zaavedra Portillo

Nicolás Daniel Arza Vega

Fecha del informe: 19 de septiembre de 2026

Índice

1. Comprensión del problema

- 1.1 Contexto — 1.2 Pregunta de investigación — 1.3 Objetivo general
- 1.4 Objetivos específicos — 1.5 Justificación — 1.6 Alcance y limitaciones

2. Comprensión y selección de los datos

- 2.1 Inventario — 2.2 Diccionario original — 2.3 Unidad de análisis — 2.4 Perfilado
- 2.5 Calidad — 2.6 Selección de variables — 2.7 Documentación de la fuente

3. Limpieza y transformación

- 3.1 a 3.5 Faltantes, duplicados, inconsistencias, tipos y variables derivadas
- 3.6 Integración — 3.7 Bitácora de limpieza

4. Análisis univariado

5. Análisis bivariado, inferencial y predictivo

- 5.1 Correlaciones — 5.2 Asociación ajustada — 5.3 Modelo predictivo
- 5.4 Linealidad y tramos — 5.5 Análisis de sensibilidad

6. Patrones, anomalías e hipótesis preliminares

7. Conclusión de la Fase 1

8. Diccionario de datos del dataset final

9. Reproducibilidad y entregables técnicos

10. Referencias bibliográficas

11. Declaración de uso de IA

Resumen ejecutivo

La Fase 1 se formula para estudiar una asociación, y no un impacto causal, entre las horas diarias de videojuegos y el rendimiento académico. El alcance se restringe al dataset de 8.000 estudiantes de 16 a 24 años suministrado para el proyecto y no pretende producir evidencia generalizable a una población real.

En la muestra limpia, las horas de juego presentan una asociación negativa con las calificaciones (Pearson $r = -0,558$; Spearman $\rho = -0,547$), mientras que las horas de estudio muestran una asociación positiva fuerte ($r = 0,734$). Las horas de sueño muestran una asociación positiva de menor magnitud ($r = 0,245$).

En el análisis ajustado por horas de estudio, sueño y uso no gaming, la asociación con el gaming permanece negativa: coeficiente = $-5,232$ puntos por hora, con errores estándar robustos HC3 y $p < 1 \times 10^{-300}$. Este resultado se interpreta como asociación ajustada, no como efecto causal.

La exploración por tramos fijos también presenta un patrón decreciente: la calificación media pasa de 82,02 en el tramo de 0 a 2 horas a 49,05 en el tramo de más de 6 y hasta 8 horas. El contraste de Kruskal-Wallis es significativo ($H = 2.278,62$; $p < 1 \times 10^{-300}$), por lo que se justifica continuar la investigación con análisis no lineales.

La Fase 1 también documenta problemas de calidad: 134 notas originales superan 100 y fueron limitadas a 100 conservando `grades_original`; 439 notas ya valían exactamente 100 en la fuente. Además, `flag_ajustado` identifica 1.671 registros con más de dos decimales, pero se reserva exclusivamente para el análisis de sensibilidad y no se interpreta como evidencia de manipulación.

1. Comprensión del problema

1.1 Contexto

Los videojuegos son una actividad de ocio frecuente entre adolescentes y adultos jóvenes y comparten el presupuesto diario de tiempo con el estudio, el sueño y otras actividades digitales. La evidencia empírica sobre su relación con el rendimiento académico no es uniforme. Estudios amplios han encontrado asociaciones pequeñas o nulas en algunos contextos, mientras que revisiones y metaanálisis recientes encuentran asociaciones negativas de magnitud pequeña o moderada, especialmente cuando se estudia el uso problemático. Esta heterogeneidad justifica formular la pregunta en términos de asociación y no de causalidad [1-4].

El proyecto analiza un conjunto de 8.000 registros de estudiantes de entre 16 y 24 años. La unidad de análisis es el estudiante individual y la variable objetivo es grades, interpretada en una escala de 0 a 100 después del tratamiento de los valores superiores a 100.

1.2 Pregunta de investigación

¿En qué medida las horas diarias dedicadas a los videojuegos se asocian con el rendimiento académico de los estudiantes de 16 a 24 años del dataset, considerando también sus horas de estudio y de sueño?

1.3 Objetivo general

Analizar la asociación entre las horas diarias dedicadas a los videojuegos y el rendimiento académico de estudiantes de 16 a 24 años del dataset, considerando las horas de estudio, de sueño y el uso no gaming de dispositivos como variables de contexto y de ajuste estadístico.

1.4 Objetivos específicos

Objetivo específico 1. Caracterizar los hábitos de uso de videojuegos de la muestra mediante las horas diarias jugadas y su categorización en niveles bajo, medio y alto, y describir la distribución del rendimiento académico.

Objetivo específico 2. Determinar la magnitud y la significación estadística de la asociación entre horas de juego y calificaciones, y compararla con la asociación observada para las horas de estudio y de sueño.

Objetivo específico 3. Evaluar si la asociación entre horas de juego y rendimiento académico se mantiene después de ajustar por horas de estudio, sueño y uso no gaming de dispositivos, evitando interpretar el ajuste como prueba de causalidad.

Objetivo específico 4. Construir un modelo de regresión lineal con partición de entrenamiento y prueba para predecir la calificación a partir de gaming_hours, study_hours y sleep_hours, comparándolo con una línea base y evaluándolo mediante RMSE, MAE y R^2 .

Objetivo específico 5. Explorar si la relación entre horas de juego y rendimiento académico es aproximadamente lineal o presenta cambios por tramos, utilizando terciles y también cortes fijos de 2, 4 y 6 horas, con una comprobación no paramétrica.

1.5 Justificación de la relevancia

La relevancia de la pregunta se plantea en términos metodológicos y educativos: permite practicar un flujo completo de ciencia de datos y estudiar, dentro de una muestra concreta, cómo distintas dimensiones del uso del tiempo se relacionan con una variable académica. Dado que el dataset presenta indicios de simulación y no documenta una estrategia de muestreo poblacional, los resultados se utilizan como ejercicio de análisis y como marco para formular hipótesis, no como evidencia suficiente para decisiones reales de estudiantes, familias o docentes.

1.6 Alcance y limitaciones previstas

- El diseño es transversal: no hay seguimiento temporal y no permite establecer causalidad ni dirección temporal entre las variables.
- El dataset no documenta una metodología de recolección real y presenta señales de simulación, por lo que la generalización externa es limitada.
- No se analizan `gaming_genre`, `reaction_time_ms` ni `addiction_score` en la fase principal porque no corresponden a los objetivos vigentes; `reaction_time_ms` mostró en el perfilado previo una correlación muy alta con `gaming_hours` ($|r|$ cercano a 0,94) y `addiction_score` contiene valores negativos no interpretables.
- El grupo `Other` de `gender` contiene 293 estudiantes (3,7 % de la muestra), por lo que las comparaciones por género tienen menor precisión para esa categoría.
- La transformación de las 134 calificaciones mayores que 100 introduce un efecto techo. Como 439 calificaciones ya eran exactamente 100 en el original, solo 134 nuevos valores alcanzan 100 por el recorte. Esta decisión puede subestimar la relación en el extremo superior y será considerada en el análisis de sensibilidad.
- `stress_level` se excluye del ajuste principal porque resulta casi determinística respecto de las horas de juego, estudio y sueño; se mantiene solamente como variable descriptiva.

2. Comprensión y selección de los datos

2.1 Inventario de archivos disponibles

La fuente del proyecto es el dataset «Gaming vs Academic Performance», publicado en Kaggle por el usuario `aiexplorer77`. La copia de entrada documentada corresponde al archivo con sufijo `_updated.csv`; la salida limpia entregada para el análisis es `gaming_academic_clean.csv`. El corte del proyecto y la fecha de verificación de la copia suministrada son el 19/09/2026. El dataset es transversal y no contiene una dimensión temporal.

2.2 Diccionario de datos del dataset original

Tabla 1. Diccionario del dataset original (14 columnas, 8.000 registros).

Campo	Descripción	Tipo	Unidad / rango o categorías	Faltantes
student_id	Identificador único del registro	Entero	1 a 8.000	0 %
age	Edad del estudiante	Entero	16 a 24 años	0 %
gender	Género autorreportado	Categórica nominal	Male / Female / Other	0 %
gaming_hours	Horas diarias dedicadas a videojuegos	N Numérica continua	0,00 a 8,00 horas	0 %
study_hours	Horas diarias de estudio	N Numérica continua	1,00 a 10,00 horas	0 %
sleep_hours	Horas diarias de sueño	N Numérica continua	4,00 a 9,00 horas	0 %
attendance	Porcentaje de asistencia a clases	N Numérica continua	60,00 % a 100,00 %	0 %
gaming_genre	Género de videojuego principal	Categórica nominal	FPS / RPG / Casual	0 %
social_activity	Nivel de actividad social	N Numérica en escala	0,00 a 5,00	0 %
device_usage	Horas diarias de uso general de dispositivos	N Numérica continua	1,10 a 13,95 horas	0 %
reaction_time_ms	Tiempo de reacción	N Numérica continua	183,26 a 347,87 ms	0 %
addiction_score	Puntaje de adicción a videojuegos	N Numérica continua	-4,51 a 23,16	0 %
stress_level	Nivel de estrés autopercebido	Categórica ordinal	Low / Medium / High	0 %
grades	Calificación o rendimiento académico	N Numérica continua	0,00 a 118,63	0 %

2.3 Unidad de análisis y clave primaria

Cada fila representa un estudiante individual. En el dataset original, student_id es único para los 8.000 registros. Para el dataset analítico final se elimina esta columna porque funciona como identificador y no como variable explicativa; la verificación de unicidad queda registrada en la etapa de perfilado.

2.4 Perfilado inicial

El dataset original contiene 8.000 filas y 14 columnas, sin valores faltantes ni filas duplicadas. Las variables categóricas gender, gaming_genre y stress_level tienen tres categorías. gaming_hours tiene una media de 4,08 horas; study_hours, de 5,45; sleep_hours, de 6,48; y grades presenta una media original aproximada de 66,18 con un máximo de 118,63. La edad presenta una distribución casi uniforme entre 16 y 24 años.

2.5 Evaluación de calidad

Se identificaron 134 registros (1,7 %) con grades mayor que 100 y 107 registros (1,3 %) con addiction_score negativo. No se detectaron faltantes ni duplicados. El máximo de grades por encima de

100 es 118,63. La ausencia de documentación sobre la escala de grados obliga a explicitar el supuesto utilizado para limitarla a 100.

2.6 Selección justificada de variables

La selección distingue entre variables conservadas en el dataset final y variables utilizadas en el análisis principal. El archivo final contiene 15 columnas porque, además de las variables directamente analíticas, conserva variables de contexto, de trazabilidad y derivadas necesarias para la reproducción. age y gender se mantienen para describir la muestra; attendance y social_activity se conservan como contexto y podrán ser exploradas posteriormente, pero no forman parte de los objetivos centrales de esta Fase 1. stress_level se conserva solamente para descripción. Para los modelos principales se utilizan gaming_hours, study_hours, sleep_hours y uso_no_gaming, mientras que device_usage no entra al mismo modelo porque es exactamente igual a gaming_hours + uso_no_gaming, lo que produce una dependencia lineal exacta.

2.7 Documentación de la fuente

Fuente: Kaggle, «Gaming vs Academic Performance», usuario aiexplorer77[5]. Archivo de trabajo: copia_updated.csv. Fecha de corte y verificación del proyecto: 19/09/2026. La fecha de recolección de los datos no está documentada. En la consulta realizada no fue posible verificar de forma confiable un número de versión del dataset ni una licencia específica de la ficha; por integridad documental se deja constancia de ello y no se asigna una licencia por inferencia.

Como referencia externa para el contexto científico se utilizaron [1] Drummond y Sauer (2014), [2] Adelantado-Renau et al. (2019), [3] Alzahrani y Griffiths (2024) y [4] Chew, Yow y Dimech (2026).

3. Limpieza y transformación

3.1 Tratamiento de valores faltantes

No se detectan valores faltantes en las 14 columnas del dataset original. Se conservan las 8.000 filas y no se aplica imputación.

3.2 Detección y tratamiento de duplicados

No existen filas duplicadas exactas ni perfiles duplicados al ignorar student_id. No se elimina ninguna fila por este criterio.

3.3 Identificación de valores atípicos e inconsistencias

La regla de 1,5 veces el rango intercuartílico no identifica atípicos en las columnas numéricas, por lo que se revisan además cuatro reglas de consistencia. No se encuentran incumplimientos en la relación $\text{device_usage} \geq \text{gaming_hours}$, en la suma $\text{gaming_hours} + \text{study_hours} + \text{sleep_hours} \leq 24$, en la asistencia dentro del intervalo de 0 a 100 ni en la ausencia de calificaciones negativas.

Sí se encuentran dos grupos de valores imposibles. El primero está formado por 134 calificaciones (1,7 %) mayores que 100, con un máximo de 118,63. Como la fuente no documenta la escala, se asume que va de 0 a 100 y se limitan esas calificaciones a 100, conservando el valor original en `grades_original` y marcando los casos en `flag_grades_gt100`. No se eliminan las filas porque corresponden a estudiantes con un perfil distinto —juegan menos y estudian más que el resto— y descartarlos sesgaría el extremo superior de la distribución. El segundo grupo está formado por 107 puntajes de adicción negativos (1,3 %), que no se corrigen porque `addiction_score` se descarta (sección 2.6).

En las variables categóricas `gender`, `gaming_genre` y `stress_level` no hay espacios sobrantes ni categorías escritas de distinta forma. Por último, `stress_level` resulta casi determinística: con reglas simples basadas en las horas de estudio, sueño y juego se reproduce en alrededor del 99,9 % de los registros, y además asocia el estrés bajo con jugar mucho (87,8 % de los estudiantes del tercil que más juega). Se conserva como variable descriptiva, pero no se usa como variable de control.

3.4 Normalización de tipos y formatos

Se eliminan los espacios externos de las variables categóricas, `gender` se define como nominal y `stress_level` como ordinal (`Low < Medium < High`). `age` se verifica como entero. Las columnas numéricas se leyeron correctamente con punto decimal y la codificación de caracteres es UTF-8. `grades` se redondea a dos decimales para la versión analítica —era la única columna con más cifras, con 1.671 valores afectados—; `grades_original` conserva la precisión de la fuente. No hay fechas ni importes que requieran otras transformaciones.

3.5 Creación de variables derivadas

uso_no_gaming = device_usage – gaming_hours. Esta identidad se verifica fila por fila dentro de la precisión numérica y permite evitar la colinealidad que aparecería al incluir simultáneamente `device_usage`, `gaming_hours` y `uso_no_gaming` en una regresión, dado que `device_usage` está muy correlacionado con las horas de juego ($r = 0,85$).

gaming_cat. Divide `gaming_hours` en terciles con cortes en 2,80 y 5,46 horas: Bajo ($n = 2.671$), Medio ($n = 2.667$) y Alto ($n = 2.662$). Se usan terciles porque generan grupos de igual tamaño sin fijar umbrales arbitrarios; para no depender únicamente de cortes relativos, la exploración se repite con tramos fijos de 0 a 2, de más de 2 a 4, de más de 4 a 6 y de más de 6 a 8 horas.

Indicadores de trazabilidad. `grades_original` conserva la calificación antes del recorte y `flag_grades_gt100` identifica los 134 casos superiores a 100. `flag_ajustado` identifica 1.671 registros con más de dos decimales antes del redondeo. Se desconoce el mecanismo que generó esa precisión adicional, por lo que no se interpreta como prueba de ajuste o de manipulación; su único uso en esta fase es como indicador para el análisis de sensibilidad.

No se crearon variables de calendario ni se deflactaron montos, porque el dataset no contiene fechas ni importes.

3.6 Integración de fuentes

No corresponde: el proyecto utiliza una sola fuente en formato CSV.

3.7 Bitácora de limpieza

Tabla 2. Bitácora de decisiones de limpieza.

Paso	Problema o revisión	Registros	Decisión	Fundamento
3.1	Valores faltantes	0	Conservar todas las filas	No hay ausencias.
3.2	Duplicados exactos y parciales	0	No eliminar	No hay filas repetidas.
3.3	Atípicos ($1,5 \times \text{IQR}$) y reglas de consistencia	0	Sin corrección	No se detectan incumplimientos.
3.3	grades mayor que 100	134	Limitar a 100; conservar grades_original y flag_grades_gt100	Se asume escala de 0 a 100; eliminar las filas sesgaría el extremo superior.
3.3	stress_level casi determinística	8.000	Conservar como descriptiva, no como control	Estructura casi derivada de las horas de rutina.
3.4	Espacios externos y tipos de las categóricas	0 espacios; 3 columnas	Normalizar	Refleja la naturaleza nominal y ordinal de cada variable.
3.4	Calificaciones con más de dos decimales	1.671	Redondear; conservar flag_ajustado	Permite sensibilidad sin interpretar el motivo.
3.5	uso_no_gaming	8.000	Crear	Evita usar device_usage junto con gaming_hours y uso_no_gaming.
3.5	gaming_cat	8.000	Crear terciles	Cortes en 2,80 y 5,46; se controla con cortes fijos.
2.6	student_id	8.000	Excluir del dataset analítico	Identificador sin valor explicativo.
2.6	addiction_score	8.000	Excluir	107 valores negativos y fuera de los objetivos.
2.6	reaction_time_ms	8.000	Excluir	El perfilado previo reportó $ r $ cercano a 0,94 con gaming_hours.
2.6	gaming_genre	8.000	Excluir	No forma parte de los objetivos vigentes.

4. Análisis univariado

La etapa univariada describe la estructura de la muestra y permite identificar asimetrías, techos, rangos y categorías pequeñas antes de interpretar relaciones. La Tabla 3 resume las variables principales.

Tabla 3. Estadísticos descriptivos de las variables analíticas.

Variable	Media	DE	Mediana	Mín.	Máx.
Edad (años)	19,98	2,59	20,00	16,00	24,00
Gaming (h/día)	4,08	2,30	4,13	0,00	8,00
Estudio (h/día)	5,45	2,56	5,46	1,00	10,00
Sueño (h/día)	6,48	1,43	6,50	4,00	9,00
Asistencia (%)	79,89	11,58	79,69	60,00	100,00

Variable	Media	DE	Mediana	Mín.	Máx.
Uso no gaming (h/día)	3,51	1,44	3,53	1,00	6,66
Calificación	66,08	22,25	67,07	0,00	100,00




Figura 1. Distribución de edad.

Interpretación. La muestra cubre todo el rango de 16 a 24 años y se distribuye casi uniformemente; esto reduce el valor de la edad como discriminador descriptivo y es compatible con la hipótesis de un dataset generado o balanceado artificialmente.




Figura 2. Distribución de horas diarias de videojuegos.

Interpretación. gaming_hours varía entre 0 y 8 horas, con media de 4,08 y mediana de 4,13. La amplitud permite comparar tanto una tendencia lineal como cambios de comportamiento por tramos.




Figura 3. Distribución de calificaciones ajustadas.

Interpretación. La media es 66,08 y la mediana 67,07. El valor 100 aparece como techo: 574 registros quedan en 100, pero solo 134 de ellos llegaron allí por el recorte de valores originalmente superiores a 100; los otros 439 ya eran 100 en la fuente.




Figura 4. Composición de la muestra por género.

Interpretación. Female (3.803) y Male (3.904) concentran casi toda la muestra. Other reúne 293 casos (3,7 %), por lo que cualquier comparación específica para esa categoría debe interpretarse con menor precisión.

4.1 Lectura univariada de calidad

No se observan faltantes. Los rangos de `gaming_hours`, `study_hours` y `sleep_hours` son internamente compatibles con la regla del presupuesto diario. La principal alerta corresponde a la variable `grades` por encima de 100 y al efecto techo resultante de la transformación. La segunda alerta metodológica es la estructura casi determinística de `stress_level`, que no debe confundirse con una medición independiente del estrés.

5. Análisis bivariado, inferencial y predictivo

5.1 Correlaciones bivariadas

Tabla 4. Correlaciones de cada variable con la calificación (grades).

Variable	Pearson r	p	Spearman rho	p
Horas de gaming	-0,558	$< 1 \times 10^{-300}$	-0,547	$< 1 \times 10^{-300}$
Horas de estudio	0,734	$< 1 \times 10^{-300}$	0,742	$< 1 \times 10^{-300}$
Horas de sueño	0,245	$5,83 \times 10^{-110}$	0,239	$6,84 \times 10^{-104}$
Uso no gaming	0,007	0,5284	0,005	0,6233
Asistencia	0,130	$1,52 \times 10^{-31}$	0,126	$1,46 \times 10^{-29}$
Actividad social	-0,019	0,0958	-0,017	0,1369
Edad	0,008	0,4688	0,010	0,3640
Uso general de dispositivos	-0,469	$< 1 \times 10^{-300}$	-0,465	$< 1 \times 10^{-300}$

La asociación de mayor interés es la de gaming_hours con grades: $r = -0,558$, con un intervalo de confianza del 95 % aproximado de $[-0,573; -0,543]$. La asociación monotónica es similar ($\rho = -0,547$), lo que reduce la posibilidad de que el resultado dependa solo de valores extremos. study_hours presenta $r = 0,734$ y sleep_hours, $r = 0,245$. uso_no_gaming no presenta una asociación lineal detectable con grades ($r = 0,007$; $p = 0,5284$).




Figura 5. Horas de juego y calificación.

Interpretación. Se observa una tendencia descendente clara. La recta resume una asociación, no un efecto causal: a medida que aumentan las horas de gaming, las calificaciones tienden a ser menores dentro de este dataset.




Figura 6. Horas de estudio y calificación.

Interpretación. La nube muestra una asociación positiva fuerte ($r = 0,734$), lo que indica que el tiempo de estudio comparte una parte importante de la variabilidad de grados y por eso debe formar parte del ajuste.




Figura 7. Horas de sueño y calificación.

Interpretación. La asociación con `sleep_hours` es positiva y de menor magnitud ($r = 0,245$). Esto sugiere que el sueño aporta información adicional, aunque claramente menos que el estudio en esta muestra.

5.2 Asociación ajustada por rutina diaria

Se estima una regresión lineal por mínimos cuadrados ordinarios con errores estándar robustos HC3, con la especificación `grades ~ gaming_hours + study_hours + sleep_hours + uso_no_gaming`. El modelo obtiene un R^2 ajustado de 0,889. Los coeficientes se interpretan como asociaciones parciales dentro del modelo.

Tabla 5. Regresión OLS de la calificación sobre las variables de rutina diaria.

Predictor	Coef.	EE HC3	p	IC 95 %
<code>gaming_hours</code>	-5,232	0,038	$< 1 \times 10^{-300}$	[-5,307; -5,156]
<code>study_hours</code>	6,268	0,034	$< 1 \times 10^{-300}$	[6,202; 6,335]

Predictor	Coef.	EE HC3	p	IC 95 %
sleep_hours	3,677	0,059	$< 1 \times 10^{-300}$	[3,562; 3,792]
uso_no_gaming	0,008	0,058	0,8869	[-0,106; 0,122]

El coeficiente de gaming_hours es -5,232: en el modelo ajustado, una hora adicional de gaming se asocia con aproximadamente 5,23 puntos menos de calificación, manteniendo constantes las otras variables del modelo. study_hours se asocia con +6,27 puntos por hora y sleep_hours con +3,68 puntos por hora. uso_no_gaming no aporta una asociación estadísticamente detectable en este modelo ($p = 0,8869$). Esto no demuestra que el gaming cause la disminución de grades: el diseño y la construcción del dataset impiden ese salto inferencial.

En cuanto a la colinealidad, se evita incluir device_usage junto con gaming_hours y uso_no_gaming. La razón es algebraica: $\text{uso_no_gaming} = \text{device_usage} - \text{gaming_hours}$, por lo que las tres columnas generan una dependencia lineal exacta. Al sustituir uso_no_gaming por device_usage, el ajuste global permanece prácticamente igual, mientras ambas variables presentan un VIF aproximado de 3,55; la versión analítica elegida mantiene la interpretación más coherente con el objetivo y evita la redundancia exacta.

5.3 Modelo predictivo y validación

Para cumplir el componente predictivo se usa una partición aleatoria 80/20 con semilla 42. El modelo es una regresión lineal entrenada con gaming_hours, study_hours y sleep_hours. Se compara contra una línea base que predice en todos los casos la media de grades del conjunto de entrenamiento. Las métricas se calculan solo sobre el conjunto de prueba.

Tabla 6. Desempeño en el conjunto de prueba (20 % de la muestra).

Modelo	RMSE	MAE	R ²
Línea base (media de entrenamiento)	22,16	18,42	-0,000
Regresión lineal	7,55	6,04	0,884

El modelo reduce el RMSE de 22,16 de la línea base a 7,55 y alcanza un R² de 0,884 en prueba. Estos indicadores muestran capacidad predictiva dentro del dataset disponible; no deben interpretarse como evidencia de desempeño en una población real ni como prueba de causalidad.

5.4 Linealidad, tramos y contraste no paramétrico




Figura 8. Calificaciones por tercil de gaming.

Interpretación. Las medias son 79,92 para Bajo, 66,87 para Medio y 51,40 para Alto. La separación es amplia y consistente con la tendencia lineal, aunque los terciles son cortes relativos a la muestra y no representan umbrales normativos.




Figura 9. Calificación media por tramos fijos de horas.

Interpretación. Los cortes fijos muestran una secuencia descendente: 82,02; 72,26; 62,50; y 49,05. La comprobación de Kruskal-Wallis arroja $H = 2.278,62$ y $p < 1 \times 10^{-300}$. Esto apoya la necesidad de estudiar posibles no linealidades sin afirmar que exista un umbral causal.

Para los terciles, Kruskal-Wallis da $H = 2.110,15$ con $p < 1 \times 10^{-300}$, y el ANOVA arroja $F = 1.512,39$ con $p < 1 \times 10^{-300}$. La diferencia entre Bajo y Alto es de 28,52 puntos de media y el tamaño de efecto estandarizado es d de Cohen = 1,49. Como los grupos son muy grandes, la significación estadística no implica por sí sola que los cortes constituyan un umbral natural.




Figura 10. Matriz de correlaciones de las variables analíticas.

Interpretación. El mapa confirma tres relaciones relevantes: gaming con grades es negativa, study con grades es positiva fuerte y sleep con grades es positiva moderada. uso_no_gaming queda cerca de cero frente a grades, y device_usage sería redundante en un modelo que ya incluye gaming y uso_no_gaming.




Figura 11. Estrés por categoría de gaming (solo descriptivo).

Interpretación. La distribución de stress_level cambia fuertemente entre categorías de gaming: el tercil Alto tiene 87,8 % de Low, mientras que el tercil Bajo no contiene casos Low. Esta estructura es una razón adicional para no usar stress_level como variable de control independiente en la Fase 1.




Figura 12. Calificaciones por género.

Interpretación. Las medias son 66,46 (Female), 65,77 (Male) y 65,25 (Other). El ANOVA no detecta diferencias estadísticamente significativas ($F = 1,15$; $p = 0,316$). El resultado es descriptivo y está condicionado por el tamaño pequeño del grupo Other.

5.5 Análisis de sensibilidad de la limpieza

Los 134 casos con `grades_original` mayor que 100 están contenidos dentro de los 1.671 registros marcados con `flag_ajustado`; no son dos grupos independientes. Para evitar confusiones, `flag_ajustado` se utiliza únicamente como análisis de sensibilidad. Con todas las filas y las calificaciones ajustadas, la correlación entre `gaming` y `grades` es $r = -0,558$; usando `grades_original`, $r = -0,557$; y excluyendo los 1.671 registros marcados, $r = -0,707$. El cambio hacia una asociación más negativa al excluir esos casos indica sensibilidad del resultado a la regla de limpieza, pero no permite concluir por qué fueron generados esos registros. La suma de `gaming`, `estudio` y `sueño` promedia 18,83 horas en los registros marcados frente a 15,26 en el resto; esta diferencia se reporta como señal de estructura de los datos y no como prueba de manipulación.

6. Patrones, anomalías e hipótesis preliminares

6.1 Tres patrones principales

- Patrón 1. Asociación negativa y consistente entre `gaming` y `grades`. Se observa en la correlación de Pearson, en la de Spearman, en la regresión ajustada y en los tramos fijos.
- Patrón 2. El estudio está más fuertemente asociado con `grades` que el `gaming`. `study_hours` presenta $r = 0,734$ y sigue siendo positivo en el modelo ajustado; esto muestra que la relación entre `gaming` y `grades` no debe analizarse aislada del uso del tiempo.
- Patrón 3. Estructuras que parecen derivadas del proceso de generación o limpieza. `stress_level` es casi determinística y `flag_ajustado` se concentra en perfiles con mayor suma diaria de `gaming`, `estudio` y `sueño`. Esto sugiere cautela al interpretar variables generadas como si fueran observaciones independientes.

6.2 Tres anomalías o cuestiones de calidad

- 134 calificaciones mayores que 100 en la fuente y efecto techo final: 574 valores iguales a 100, de los cuales 439 ya eran 100 y 134 provienen del recorte.
- 107 valores negativos en `addiction_score`, aunque esta variable se excluye de la Fase 1.
- El grupo Other de gender contiene 293 casos (3,7 %); `stress_level` muestra ausencia total de Low en el tercil Bajo de gaming y 87,8 % de Low en el tercil Alto.

6.3 Hipótesis preliminares para las siguientes fases

- H1. La asociación entre horas de juego y calificación permanece negativa después de ajustar por horas de estudio y de sueño.
- H2. Las horas de estudio explican una parte importante de la variabilidad de grades y deben incluirse en cualquier modelo que intente separar asociaciones de uso del tiempo.
- H3. La asociación entre gaming y grades puede presentar cambios de pendiente o comportamiento por tramos, por lo que los modelos no lineales deben compararse con la regresión lineal.
- H4. El uso no gaming de dispositivos aporta poca información incremental para grades una vez consideradas las horas de gaming, estudio y sueño.
- H5. Los resultados pueden ser sensibles al tratamiento de los registros marcados con `flag_ajustado` y al efecto techo de grades; la robustez debe comprobarse con análisis de sensibilidad.

7. Conclusión de la Fase 1

La Fase 1 deja definido un problema de investigación que es estadísticamente contrastable sin convertir una asociación observacional en una afirmación causal. El título, la pregunta y los objetivos utilizan la misma lógica: estudiar la asociación entre las horas diarias de videojuegos y el rendimiento académico dentro de los estudiantes de 16 a 24 años incluidos en el dataset. Esta formulación es especialmente importante porque la literatura externa tampoco ofrece una única respuesta: algunos estudios de gran escala encontraron asociaciones muy pequeñas o nulas, mientras que revisiones posteriores documentan asociaciones negativas, especialmente cuando se define o se mide el uso problemático. Por ello, el valor de esta fase no es confirmar una explicación universal, sino construir un análisis reproducible que permita verificar qué ocurre en esta base concreta [1-4].

El perfilado de datos muestra una muestra completa, sin faltantes ni duplicados, pero con problemas de calidad que condicionan la interpretación. Hay 134 notas por encima de 100 y 107 valores negativos en `addiction_score`. La limpieza decide limitar las notas superiores a 100, conservar `grades_original` y registrar `flag_grades_gt100`. La revisión detallada evita un error conceptual frecuente: no se afirma que los 574 valores finales en 100 sean todos producidos por el recorte, porque 439 ya eran exactamente 100 en la fuente. El efecto techo, por tanto, existía parcialmente desde el principio y se amplía con la

transformación. La limitación queda explicitada porque este techo puede reducir la capacidad de distinguir diferencias en el extremo superior.

La selección de variables también queda alineada con los objetivos. `student_id` deja de ser parte del dataset analítico; `gaming_genre`, `reaction_time_ms` y `addiction_score` se excluyen por no ser necesarias para los objetivos vigentes, con el tratamiento de calidad correspondiente. `age` y `gender` permanecen como contexto descriptivo, mientras que `attendance` y `social_activity` permanecen disponibles pero no se incorporan a los modelos principales. `stress_level` se conserva solo como variable descriptiva porque su estructura es casi determinística y puede introducir un supuesto de control artificial. El tratamiento del uso de dispositivos se simplifica mediante `uso_no_gaming`, y `device_usage` se excluye de los modelos que ya contienen `gaming_hours` y `uso_no_gaming` debido a la identidad exacta entre las tres variables.

En los resultados bivariados, `gaming_hours` presenta una asociación negativa con `grades` ($r = -0,558$) y `study_hours` una asociación positiva fuerte ($r = 0,734$); `sleep_hours` presenta una asociación positiva menor ($r = 0,245$). La asociación del gaming no desaparece al ajustar por estudio, sueño y uso no gaming: el coeficiente permanece negativo, en aproximadamente $-5,23$ puntos de calificación por hora, mientras que el estudio y el sueño mantienen coeficientes positivos. Sin embargo, estos coeficientes son asociaciones parciales dentro de una base transversal y no constituyen estimaciones de efectos causales.

El componente predictivo cumple la exigencia de separar entrenamiento y prueba y de comparar contra una línea base. Con `gaming_hours`, `study_hours` y `sleep_hours`, la regresión obtiene $RMSE = 7,55$, $MAE = 6,04$ y $R^2 = 0,884$ en prueba, frente a un $RMSE$ de $22,16$ para la predicción de la media. Esto muestra que las variables consideradas contienen información predictiva dentro del dataset. No obstante, la capacidad predictiva no debe trasladarse automáticamente a una afirmación causal ni a un desempeño esperado fuera de esta muestra.

Finalmente, la exploración por tramos fijos aporta una comprobación útil frente a la arbitrariedad de los terciles. Las medias de calificación disminuyen de manera ordenada a medida que aumenta el intervalo de gaming, y el contraste de Kruskal-Wallis detecta diferencias entre grupos. Esto no demuestra la existencia de un umbral natural; solo indica que la relación puede estudiarse también con cortes interpretables y con métodos no paramétricos. Las hipótesis de la siguiente fase quedan así centradas en la robustez, la no linealidad y la validación de modelos, incluyendo la sensibilidad al efecto techo y a los registros marcados con `flag_ajustado`.

En conjunto, la Fase 1 entrega una base coherente para continuar: un problema bien delimitado, variables y reglas de limpieza documentadas, análisis descriptivos e inferenciales iniciales, un componente predictivo validado con partición de prueba y un conjunto explícito de limitaciones. El siguiente paso debe mantener la misma disciplina: distinguir asociación de causalidad, comprobar la

robustez de los resultados y evitar interpretar estructuras potencialmente generadas del dataset como evidencia independiente.

8. Diccionario de datos del dataset final

Tabla 7. Diccionario del dataset analítico final (15 columnas).

Campo	Descripción	Tipo	Rango / categorías	Faltantes
age	Edad del estudiante	Entero	16 a 24 años	0 %
gender	Género autorreportado	Catagórica nominal	Female / Male / Other	0 %
gaming_hours	Horas diarias de videojuegos	Numérica continua	0,00 a 8,00 horas	0 %
study_hours	Horas diarias de estudio	Numérica continua	1,00 a 10,00 horas	0 %
sleep_hours	Horas diarias de sueño	Numérica continua	4,00 a 9,00 horas	0 %
attendance	Porcentaje de asistencia	Numérica continua	60,00 % a 100,00 %	0 %
social_activity	Nivel de actividad social	Numérica en escala	0,00 a 5,00	0 %
device_usage	Uso general de dispositivos; se conserva como fuente pero no entra junto a gaming y uso_no_gaming	Numérica continua	1,10 a 13,95 horas	0 %
uso_no_gaming	Uso de dispositivos ajeno al gaming = device_usage – gaming_hours	Numérica continua	1,00 a 6,66 horas	0 %
stress_level	Nivel de estrés; solo descriptivo en esta fase	Catagórica ordinal	Low / Medium / High	0 %
gaming_cat	Categoría de gaming por terciles	Catagórica ordinal	Bajo / Medio / Alto	0 %
grades	Calificación analítica, limitada a 100 y redondeada a dos decimales	Numérica continua	0,00 a 100,00	0 %
grades_original	Calificación original antes del recorte y del redondeo	Numérica continua	0,00 a 118,63	0 %
flag_grades_gt100	Indica grades_original mayor que 100	Booleana	False / True	0 %
flag_ajustado	Indica más de dos decimales antes del redondeo; solo sensibilidad	Booleana	False / True	0 %

Nota: el dataset final no contiene student_id, gaming_genre, reaction_time_ms ni addiction_score. Esas variables aparecen únicamente en el diccionario original y en la trazabilidad de limpieza.

9. Declaración de uso de IA

Para la elaboración de esta Fase 1 se utilizó una herramienta de inteligencia artificial como apoyo para revisar la coherencia interna del documento, proponer redacciones, organizar la estructura y asistir en la generación y verificación de cálculos, tablas y visualizaciones. El contenido analítico se contrastó con el CSV suministrado y con las referencias bibliográficas indicadas. Las decisiones metodológicas, los supuestos de limpieza, la interpretación de los resultados y la responsabilidad por el contenido del informe corresponden al equipo autor.

La asistencia de IA no se considera una fuente primaria de evidencia. Cuando se incorporaron afirmaciones sobre literatura científica, se utilizaron las referencias citadas en la sección 10. No se presenta como hecho ninguna inferencia que no esté respaldada por los datos o por una fuente identificada.