INFORME DE LA FASE 3
Modelado predictivo del rendimiento académico

Proyecto Integrador de Ciencia de Datos

José Zaavedra - Nicolás Arza
Ingeniería Informática · Data Science

1. Objetivo y contexto

La Fase 3 busca construir y evaluar modelos de regresión para estimar la variable **grades**, correspondiente a la calificación académica en una escala de 0 a 100. Los datos corresponden a un grupo anonimizado de estudiantes universitarios de Estados Unidos. No se especifican las universidades, carreras ni toda la composición demográfica, por lo que los resultados se interpretan como una aproximación para el grupo observado y no como una generalización universal.

Se utilizan como predictores gaming_hours, study_hours, sleep_hours, attendance y uso_no_gaming. No se utilizan grades_original, banderas de limpieza ni variables derivadas de la respuesta.

2. Correcciones y decisiones respecto de Fase 2

Se conserva el dataset limpio y se documenta una inconsistencia de trazabilidad. En Fase 2 se había utilizado uso_no_gaming como predictor complementario, mientras que la primera versión de Fase 3 lo había reemplazado por social_activity sin una comparación sistemática. En esta versión se comparan tres alternativas: uso_no_gaming, social_activity y ambas variables. La comparación se realiza únicamente sobre entrenamiento mediante validación cruzada de cinco particiones, sin utilizar la prueba para seleccionar predictores.

La combinación con uso_no_gaming obtuvo el menor RMSE promedio, aunque la diferencia fue pequeña. Por eso se conserva por continuidad con Fase 2 y por evidencia predictiva, sin afirmar una superioridad fuerte ni causal.

3. Datos y preparación

El dataset contiene 8.000 observaciones y 15 columnas, sin valores faltantes ni duplicados completos. En la preparación se detectaron 134 calificaciones superiores a 100. Se limitaron a 100 para respetar la escala objetivo y se conservó la variable original para mantener la trazabilidad. También se excluyeron variables problemáticas o redundantes documentadas en las fases anteriores.

Quedaron 574 calificaciones iguales a 100. Este efecto techo es una limitación relevante porque puede sesgar las predicciones altas y explica parte de los errores extremos observados.

4. Diseño experimental

Se realizó una partición aleatoria reproducible de 80% para entrenamiento y 20% para prueba, equivalente a 6.400 y 1.600 estudiantes. La semilla utilizada fue 42. La prueba se mantuvo aislada hasta la evaluación final. Dentro del entrenamiento se utilizó validación cruzada de cinco particiones y GridSearchCV para optimizar hiperparámetros.

Conjunto de predictores	Mejor modelo	RMSE CV
Fase 2 + uso_no_gaming	Random Forest	5,806
Fase 3 + social_activity	Random Forest	5,819
Ambos complementarios	Random Forest	5,827

5. Modelos comparados

Se comparó una línea base DummyRegressor, que predice siempre la media del entrenamiento, contra tres familias: regresión lineal, Random Forest y KNN. La línea base permite comprobar que los modelos aprendan relaciones útiles y no solo reproduzcan una predicción constante.

6. Resultados en prueba

Modelo	RMSE	MAE	MAPE (%)	R^2
Random Forest	6,00	4,61	8,96	0,927
KNN	6,33	4,97	10,05	0,918
Regresión lineal	6,98	5,54	10,56	0,901
Línea base	22,16	18,59	—	≈ 0

Random Forest fue el modelo ganador. En prueba, sus predicciones se alejaron en promedio 4,61 puntos de las calificaciones reales y explicaron aproximadamente el 92,7% de la variabilidad observada en ese conjunto. Estas métricas describen el grupo analizado y no garantizan el mismo desempeño en otra población.

7. Generalización y errores

El RMSE de Random Forest fue aproximadamente 3,21 en entrenamiento, 5,78 en validación y 6,00 en prueba. El aumento entre entrenamiento y datos no vistos muestra una brecha esperable; la diferencia pequeña entre validación y prueba indica un comportamiento relativamente estable dentro de este experimento. Los peores errores llegaron aproximadamente a 26 puntos y se concentraron especialmente cerca del tope de 100.

8. Interpretación de variables

La importancia por permutación mostró que study_hours fue el predictor más relevante, seguido de gaming_hours. Luego aparecieron sleep_hours y attendance, mientras que uso_no_gaming tuvo una contribución cercana a cero. Esta medida indica utilidad predictiva relativa, no causalidad. Que una variable sea importante para el modelo no significa que modificarla produzca automáticamente un cambio determinado en las calificaciones.

Variable	Importancia media
study_hours	17,98
gaming_hours	12,74
sleep_hours	3,70
attendance	1,37
uso_no_gaming	0,02

9. Limitaciones, ética y uso

Los datos corresponden a estudiantes de Estados Unidos y no se conocen con precisión sus universidades, carreras ni toda su composición. Las diferencias culturales entre estudiantes estadounidenses y paraguayos pueden modificar hábitos, condiciones educativas y relaciones con el rendimiento. También pueden existir variables omitidas, como rendimiento previo, motivación, contexto socioeconómico y calidad de enseñanza. Además, se cuenta con una sola medición y no se documenta completamente el procedimiento de muestreo.

Por estas razones, el modelo debe utilizarse como herramienta exploratoria y no para etiquetar, sancionar o tomar decisiones académicas individuales. Para aplicarlo en Paraguay sería necesario validarlo con una muestra local, independiente y documentada.

10. Conclusión

La Fase 3 mostró que Random Forest fue el mejor de los modelos evaluados y superó ampliamente la línea base. Las horas de estudio y de videojuegos fueron los predictores más relevantes dentro del conjunto analizado. Sin embargo, los resultados representan asociaciones y capacidad predictiva dentro de un grupo anonimizado de estudiantes universitarios de Estados Unidos; no demuestran causalidad ni permiten generalizar automáticamente a estudiantes de Paraguay. La principal mejora metodológica de esta versión fue documentar y comparar la selección de uso_no_gaming y social_activity antes de evaluar la prueba.

Asistencia de IA: se utilizó como apoyo para revisar redacción, documentación y aspectos técnicos. El grupo verificó el código, los resultados y las interpretaciones incluidos en el informe.