FACULTAD POLITÉCNICA · UNIVERSIDAD NACIONAL DE ASUNCIÓN
Ingeniería en Informática · Data Science

INFORME INTEGRADOR

Hábitos cotidianos y rendimiento académico: asociación, inferencia y predicción en estudiantes universitarios

Consolidación de las tres fases del Proyecto Integrador de Ciencia de Datos, con conclusión general del proyecto

Integrantes	José Emmanuel Zaavedra Portillo	Legajo: _____
	Nicolás Daniel Arza Vega	Legajo: _____
Materia	Data Science	
Docente	Prof. D.Sc. Margarita Ruiz	
Alcance	Fase 1 (comprensión y exploración), Fase 2 (inferencia), Fase 3 (modelado predictivo, versión revisada)	
Fecha	Noviembre de 2026	

Índice

1 Introducción **1**

2 Datos y alcance **2**

2.1 Origen y características de la muestra 2

2.2 Variables y selección 2

2.3 Calidad de los datos 2

3 Fase 1: exploración y hallazgos descriptivos **3**

3.1 Distribuciones 3

3.2 Relaciones bivariadas 4

3.3 Tramos de horas de juego 4

3.4 Asociación ajustada y sensibilidad 5

3.5 Hipótesis que pasaron a la Fase 2 5

4 Fase 2: inferencia estadística **5**

4.1 Hipótesis, supuestos y diseño de los contrastes 5

4.2 Resultados 6

4.3 Alcance de las conclusiones 7

5 Fase 3: modelado predictivo **7**

5.1 Diseño del experimento 7

5.2 Selección de predictores 8

5.3 Resultados en validación y en prueba 8

5.4 Sobreajuste 9

5.5 Análisis de errores 9

5.6 Importancia de las variables 10

6 Integración de los hallazgos **11**

7 Limitaciones **12**

8 Ética, uso responsable y trabajo futuro **12**

9 Conclusión general **13**

Declaración de uso de asistentes de IA **13**

Referencias **13**

Hábitos cotidianos y rendimiento académico: asociación, inferencia y predicción en estudiantes universitarios

José Emmanuel Zaavedra Portillo · Nicolás Daniel Arza Vega

Facultad Politécnica, Universidad Nacional de Asunción · Data Science · Noviembre de 2026

Resumen. Este informe reúne las tres fases de un proyecto de ciencia de datos que estudia cómo se relacionan los hábitos diarios con las calificaciones de un grupo anonimizado de 8.000 estudiantes universitarios de Estados Unidos, de entre 16 y 24 años. La variable de interés es `grades`, en escala de 0 a 100. En la Fase 1 se depuró el conjunto de datos y se describieron sus patrones; en la Fase 2 se contrastaron cuatro hipótesis con pruebas ajustadas por comparaciones múltiples; en la Fase 3 se construyeron modelos predictivos validados sobre un conjunto de prueba reservado. Las horas de videojuegos mostraron una asociación negativa con las calificaciones (Spearman $\rho_s = -0{,}547$; IC 95 % $[-0{,}563;\ -0{,}531]$) y las horas de estudio una asociación positiva más fuerte ($\rho_s = 0{,}742$). Con el modelo Random Forest, que conserva `uso_no_gaming` como predictor complementario tras compararlo con `social_activity`, el error en prueba fue RMSE = 6,00, MAE = 4,61 y $R^2 = 0{,}927$, frente a un RMSE de 22,16 de la línea base. Los resultados son asociaciones y capacidad predictiva dentro de este grupo; no establecen causalidad y no pueden trasladarse directamente a estudiantes de Paraguay. Para validarlos harían falta datos locales, una muestra documentada, variables contextuales y mediciones repetidas.

Palabras clave. rendimiento académico, videojuegos, hábitos de estudio, inferencia estadística, Random Forest, validación cruzada.

1 Introducción

Los videojuegos ocupan una parte importante del tiempo libre de adolescentes y adultos jóvenes, y ese tiempo compite con el estudio y el sueño dentro de un día que tiene 24 horas. La literatura sobre su relación con el rendimiento académico no es uniforme. Un análisis de datos de estudiantes de 15 años no halló un efecto negativo del juego sobre ciencias, matemática o lectura (Drummond y Sauer, 2014), mientras que una revisión sistemática con metaanálisis sobre niños y adolescentes encontró asociaciones negativas pequeñas con el tiempo dedicado a videojuegos y a televisión, aunque no con el tiempo total de pantalla (Adelantado-Renau et al., 2019). Una revisión sistemática más reciente se ocupó específicamente del juego problemático y el rendimiento de los estudiantes (Alzahrani y Griffiths, 2024). Esa heterogeneidad es la razón por la que este proyecto formula su pregunta como una asociación medible dentro de un conjunto de datos concreto, y no como una afirmación sobre el efecto de jugar.

La pregunta de investigación se fijó en la Fase 1 y no cambió: *¿en qué medida las horas diarias dedicadas a los videojuegos se asocian con el rendimiento académico de los estudiantes de 16 a 24 años del conjunto de datos, considerando también sus horas de estudio y de sueño?* El proyecto avanzó en tres etapas que se apoyan una en otra. La primera comprendió el problema, seleccionó y limpió los datos y describió la muestra. La segunda sometió a contraste estadístico las hipótesis que surgieron de esa descripción. La tercera dejó de preguntar si existe una asociación para preguntar cuánto error comete un modelo al estimar la calificación de un estudiante que no participó en su entrenamiento.

Este documento consolida esas tres etapas y responde la pregunta inicial al final. Utiliza la versión revisada de la Fase 3, en la que el conjunto de predictores se decidió mediante una comparación explícita y no por una elección sin respaldo, tal como se explica en la sección 5.2. Las cifras de este informe provienen de los notebooks ejecutados y de las tablas guardadas en el repositorio del proyecto; cuando difieren de las que figuran en entregas anteriores, se indica.

Tabla 1. Variables del conjunto analítico final que intervienen en el proyecto.

Variable	Descripción	Rango o categorías
`grades`	Calificación (variable objetivo), limitada a 100 y redondeada a dos decimales	0,00 a 100,00
`gaming_hours`	Horas diarias de videojuegos	0,00 a 8,00 h
`study_hours`	Horas diarias de estudio	1,00 a 10,00 h
`sleep_hours`	Horas diarias de sueño	4,00 a 9,00 h
`attendance`	Porcentaje de asistencia a clases	60 a 100 %
`uso_no_gaming`	Uso de dispositivos distinto del gaming, igual a `device_usage` menos `gaming_hours`	1,00 a 6,66 h
`social_activity`	Nivel de actividad social, en escala	0,00 a 5,00
`gaming_cat`	Terciles de `gaming_hours`, con cortes en 2,80 y 5,46 h	Bajo / Medio / Alto
`grades_original`	Calificación antes del recorte y del redondeo, solo para trazabilidad	0,00 a 118,63

2 Datos y alcance

2.1 Origen y características de la muestra

El conjunto de datos es «Gaming vs Academic Performance», publicado en Kaggle por el usuario `aiexplorer77`. Contiene 8.000 registros de estudiantes de entre 16 y 24 años, de los cuales 3.904 figuran como hombres, 3.803 como mujeres y 293 (3,7 %) en la categoría «Other». Corresponde a un grupo anonimizado de estudiantes universitarios de Estados Unidos. La fuente no especifica las universidades, las carreras ni toda la composición demográfica, no documenta cómo se recolectó la información ni incluye fechas de medición. Tampoco fue posible verificar una versión ni una licencia en la ficha del conjunto, y por eso no se asigna ninguna por inferencia.

Hay además señales de que el archivo pudo generarse artificialmente, algo que las Fases 1 a 3 trataron con cautela: la edad se distribuye casi de manera uniforme entre 16 y 24 años, el nivel de estrés autopercibido (`stress_level`) puede reproducirse en alrededor del 99,9 % de los registros con reglas simples sobre las horas de juego, estudio y sueño, y el conjunto carece de identificador de estudiante en su versión analítica. Por estos motivos todo resultado se interpreta como una aproximación válida para este archivo, y no como una conclusión sobre estudiantes en general ni, en particular, sobre estudiantes paraguayos.

2.2 Variables y selección

Cada fila representa a un estudiante y no hay dimensión temporal, de modo que el diseño es transversal. El archivo original tiene 14 columnas; el conjunto analítico final tiene 15, porque se descartaron cuatro variables y se agregaron cinco derivadas o de trazabilidad. Se excluyeron `student_id` (identificador sin valor explicativo), `addiction_score` (107 valores negativos no interpretables), `reaction_time_ms` (correlación de aproximadamente 0,94 en valor absoluto con las horas de juego) y `gaming_genre`, que no respondía a los objetivos. La tabla 1 resume las variables que intervienen en el análisis.

`device_usage` se conserva en el archivo pero no entra junto a `gaming_hours` y `uso_no_gaming`, porque las tres columnas son linealmente dependientes. `stress_level` se mantiene solo como variable descriptiva y no se usa como control, por la estructura casi determinística descrita arriba. Las demás variables de contexto, entre ellas `age` y `gender`, sirven para describir a la muestra.

2.3 Calidad de los datos

El archivo no tiene valores faltantes ni filas duplicadas, y las reglas de consistencia (la suma de horas de juego, estudio y sueño no supera las 24 horas, la asistencia está entre 0 y 100, no hay notas negativas) se cumplen en todos los registros. El problema de calidad más importante estaba en la variable objetivo: 134 calificaciones (1,7 %) superaban 100, con un máximo de 118,63. Como la fuente no documenta la

Tabla 2. Decisiones principales de limpieza y su fundamento.

Problema detectado	Registros	Decisión y fundamento
Valores faltantes y duplicados	0	Se conservan las 8.000 filas; no hay nada que imputar ni eliminar.
`grades` mayor que 100	134	Se limita a 100 y se conserva el valor original; eliminar filas sesgaría el extremo superior.
Calificaciones con más de dos decimales	1.671	Se redondea y se marca con `flag_ajustado`, solo para sensibilidad.
`addiction_score` negativo	107	Se descarta la variable; los valores no son interpretables y no responde a los objetivos.
`reaction_time_ms` muy correlacionada con el gaming	8.000	Se excluye por redundancia con `gaming_hours`.
`device_usage` dependiente de otras dos columnas	8.000	Se reemplaza por `uso_no_gaming` en los modelos.

Tabla 3. Estadísticos descriptivos de las variables analíticas ($n = 8.000$).

Variable	Media	DE	Mediana	Mín.	Máx.
Calificación	66,08	22,25	67,07	0,00	100,00
Videojuegos (h/día)	4,08	2,30	4,13	0,00	8,00
Estudio (h/día)	5,45	2,56	5,46	1,00	10,00
Sueño (h/día)	6,48	1,43	6,50	4,00	9,00
Asistencia (%)	79,89	11,58	79,69	60,00	100,00
Uso no gaming (h/día)	3,51	1,44	3,53	1,00	6,66
Actividad social (0–5)	2,51	1,44	2,50	0,00	5,00

escala, se asumió que va de 0 a 100 y esos valores se limitaron a 100. No se eliminaron las filas, porque correspondían a estudiantes con un perfil distinto, que juegan menos y estudian más que el resto, y quitarlos habría sesgado el extremo superior de la distribución. La calificación original se conservó en `grades_original` y los casos recortados quedaron marcados en `flag_grades_gt100`.

Esta decisión deja un efecto techo que condiciona todo el análisis. Tras la limpieza hay 574 calificaciones iguales a 100 (7,2 % de la muestra). De ellas, 439 ya valían exactamente 100 en la fuente, 134 provienen del recorte y una resulta del redondeo a dos decimales de un valor de 99,995. Por lo tanto, el techo no lo creó la limpieza, pero sí lo amplió, y reduce la capacidad de distinguir entre estudiantes de rendimiento alto, algo que reaparece al analizar los errores del modelo.

Otro detalle de la fuente es que 1.671 calificaciones tenían más de dos decimales. Se redondearon y se registraron en `flag_ajustado`. No se sabe por qué esos registros tienen mayor precisión, de modo que el indicador se utiliza únicamente en el análisis de sensibilidad y no se interpreta como señal de manipulación. La tabla 2 sintetiza las decisiones de limpieza; el detalle completo está en la bitácora del repositorio.

3 Fase 1: exploración y hallazgos descriptivos

3.1 Distribuciones

La tabla 3 resume las variables analíticas. Las horas de juego tienen media de 4,08 y mediana de 4,13, con un rango que cubre todo el intervalo de 0 a 8 horas, lo que permite comparar tanto una tendencia lineal como cambios por tramos. La calificación promedia 66,08 puntos con desviación estándar de 22,25 y mediana de 67,07; su histograma (figura 1) muestra el apilamiento en el valor 100 descrito en la sección anterior.

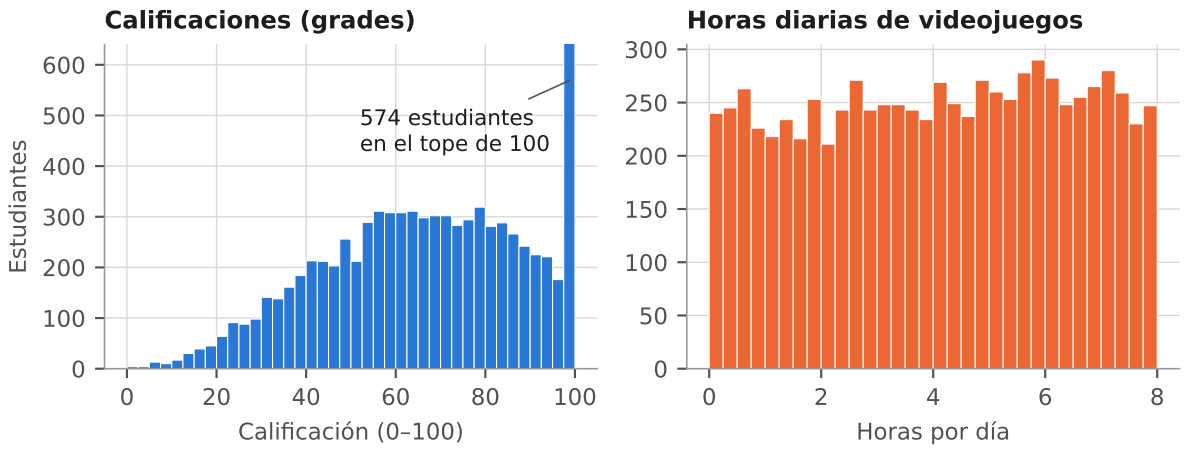


Figura 1. Distribución de las calificaciones tras el recorte a 100 (izquierda) y de las horas diarias de videojuegos (derecha).

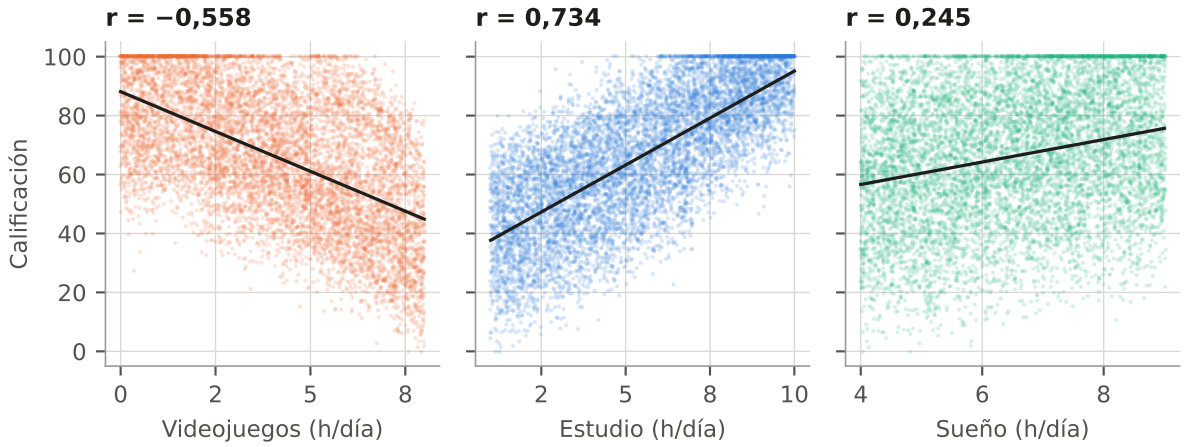


Figura 2. Calificación frente a horas de videojuegos, de estudio y de sueño. Cada punto es un estudiante; la recta es el ajuste lineal simple y r es la correlación de Pearson.

3.2 Relaciones bivariadas

Al relacionar cada hábito con la calificación aparecen tres patrones nítidos (figura 2). Las horas de videojuegos tienen una correlación de Pearson de $-0{,}558$ con las calificaciones, con intervalo de confianza del 95 % aproximado de $[-0{,}573;\ -0{,}543]$, y la correlación de Spearman es muy similar ($-0{,}547$), lo que descarta que el resultado dependa de unos pocos valores extremos. Las horas de estudio presentan la asociación más fuerte, con $r = 0{,}734$ y $\rho_s = 0{,}742$, mientras que el sueño tiene una asociación positiva más modesta ($r = 0{,}245$) y la asistencia otra aún menor ($r = 0{,}130$). El uso de dispositivos ajeno al gaming y la actividad social no muestran relación lineal detectable con la calificación ($r = 0{,}007$ y $r = -0{,}019$, con $p = 0{,}528$ y $p = 0{,}096$ respectivamente).

3.3 Tramos de horas de juego

Para no depender de una forma funcional, la relación entre juego y calificación se examinó por terciles y por tramos fijos. Las calificaciones medias de los terciles Bajo, Medio y Alto son 79,92, 66,87 y 51,40, y la diferencia entre los extremos es de 28,52 puntos (d de Cohen = 1,49). Con tramos fijos de 2 horas, la media baja de 82,02 en el tramo de 0 a 2 horas a 72,26, 62,50 y 49,05 en los tramos sucesivos (figura 3). Las caídas entre tramos consecutivos son de 9,76, 9,76 y 13,45 puntos, es decir, bastante regulares con un descenso algo más pronunciado al final. La prueba de Kruskal-Wallis es significativa en ambos esquemas ($H = 2.110{,}15$ para terciles y $H = 2.278{,}62$ para tramos fijos). Los terciles son cortes relativos a la muestra, así que no deben leerse como umbrales a partir de los cuales el juego empiece a «perjudicar».

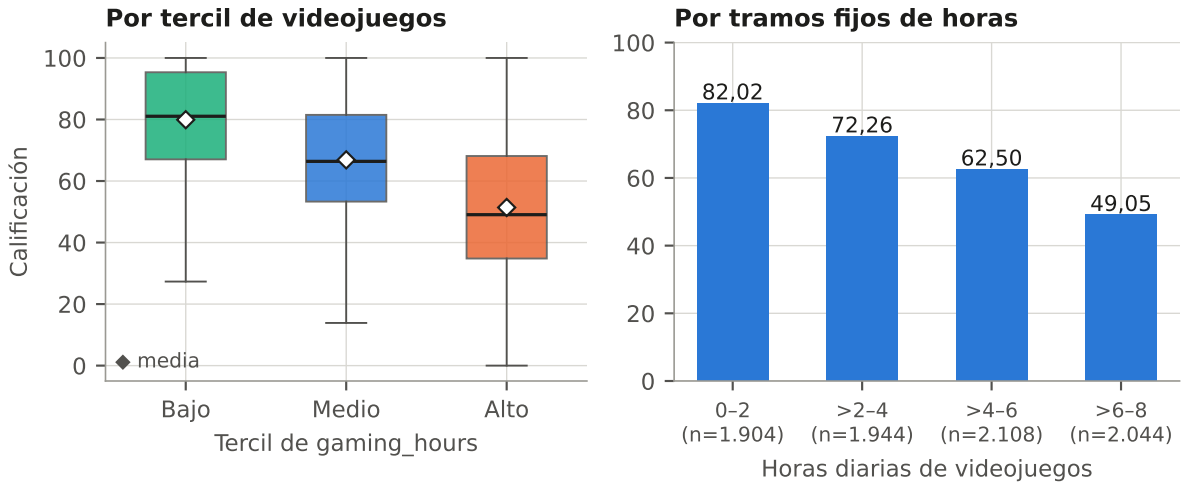


Figura 3. Calificación según el nivel de videojuegos. Izquierda: distribución por tercil, con la media indicada por el rombo. Derecha: media por tramos fijos de dos horas, con el número de estudiantes de cada tramo.

3.4 Asociación ajustada y sensibilidad

Una regresión lineal con errores estándar robustos HC3 sobre horas de juego, estudio, sueño y uso no gaming dio un coeficiente de $-5{,}232$ puntos por hora de juego, $+6{,}268$ por hora de estudio y $+3{,}677$ por hora de sueño, con un R^2 ajustado de 0,889; el uso no gaming no aportó nada detectable (coeficiente 0,008; $p = 0{,}887$). La asociación del gaming se mantiene, por lo tanto, al descontar el tiempo de estudio y de sueño, aunque son coeficientes parciales de un diseño transversal y no efectos causales.

El resultado resistió el cambio de la regla de limpieza: la correlación entre horas de juego y calificación es $-0{,}558$ con las calificaciones limitadas y $-0{,}557$ con las originales. En cambio, al excluir los 1.671 registros marcados por `flag_ajustado` la correlación sube a $-0{,}707$, lo que indica que esos registros, que tienen en promedio una suma diaria de horas mayor (18,83 frente a 15,26), atenúan la asociación. La Fase 1 no pudo explicar su origen y lo dejó documentado como señal de la estructura del archivo.

3.5 Hipótesis que pasaron a la Fase 2

La exploración dejó planteado un conjunto de hipótesis: que la asociación negativa del gaming persiste al ajustar por estudio y sueño, que el estudio explica una parte grande de la variabilidad de las calificaciones, que la relación puede cambiar de pendiente según el nivel de otras variables, que el uso no gaming aporta poca información adicional y que los resultados pueden ser sensibles al efecto techo. La Fase 1 incluyó además un primer modelo lineal con partición de entrenamiento y prueba, pero sus métricas no pudieron reproducirse desde las celdas ejecutadas del notebook. Esa observación llevó a retirarlas en la Fase 2 y a rehacer toda la evaluación predictiva en la Fase 3, por lo que este informe no las utiliza.

4 Fase 2: inferencia estadística

4.1 Hipótesis, supuestos y diseño de los contrastes

La Fase 2 unificó las hipótesis de la exploración en cuatro: H1, que las horas de juego se asocian con las calificaciones; H2, que las horas de estudio se asocian con ellas; H3, que la diferencia de calificaciones entre niveles de juego cambia según el nivel de estudio; y H4, que el sueño (H4a) y la asistencia (H4b) se asocian con las calificaciones. El nivel de significancia se fijó en $\alpha = 0{,}05$ antes de ejecutar ninguna prueba, con alternativas bilaterales, y la regla de decisión fue rechazar H_0 cuando el valor p ajustado de su familia fuera menor que 0,05.

Cada prueba se eligió después de revisar sus supuestos. Shapiro-Wilk y los gráficos Q-Q rechazaron normalidad en todas las variables, de modo que las correlaciones se calcularon con Spearman y Pearson

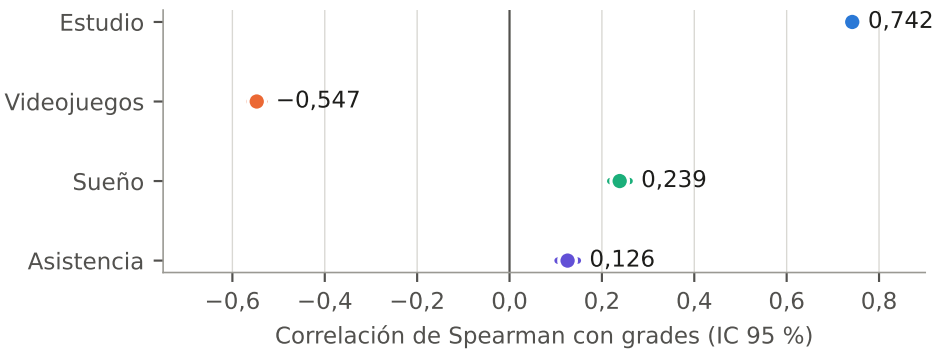


Figura 4. Correlaciones de Spearman con la calificación e intervalos de confianza del 95 % (Fase 2). Todos los contrastes son significativos tras la corrección de Benjamini-Hochberg.

quedó como referencia descriptiva. Para comparar los tres terciles de gaming, Levene detectó varianzas desiguales ($W = 103{,}77$; $p = 3{,}2 \times 10^{-45}$), lo que llevó a Kruskal-Wallis con comparaciones post hoc de Dunn. En la regresión múltiple, los residuos se apartan levemente de la normalidad (Shapiro-Wilk $W = 0{,}9984$, $p = 8{,}05 \times 10^{-5}$), pero el gráfico Q-Q sigue la recta salvo en las colas; se conservó el ajuste por mínimos cuadrados y se hizo la inferencia por permutación de Freedman-Lane (1.999 permutaciones), con intervalos bootstrap de 1.000 remuestreos. El modelo factorial de dos factores usó la misma técnica con 999 permutaciones, porque Levene también rechazó la igualdad de varianzas entre las nueve celdas.

En total se realizaron 14 contrastes principales y 3 comparaciones post hoc. Se aplicó la corrección de Benjamini-Hochberg dentro de cada familia (correlaciones, regresión y factorial), y las tres comparaciones de Dunn se ajustaron como una familia aparte. La independencia de las observaciones no puede comprobarse con este archivo, que no tiene identificador de estudiante ni información de muestreo; se declara como limitación y no como supuesto verificado.

4.2 Resultados

La tabla 4 reúne los resultados principales. Las cuatro correlaciones de Spearman con la calificación son significativas tras el ajuste. Las horas de estudio tienen la asociación mayor ($\rho_s = 0{,}742$) y las de videojuegos la sigue en magnitud con signo contrario ($\rho_s = -0{,}547$); sueño y asistencia son positivas y pequeñas (0,239 y 0,126). La figura 4 permite ver que los intervalos son estrechos y no se solapan entre las variables principales.

Entre los terciles de gaming (H1), Kruskal-Wallis arroja $H(2) = 2.110{,}15$ con $\varepsilon^2 = 0{,}264$ (IC bootstrap 95 % $[0{,}247;\ 0{,}281]$), y Dunn distingue los tres pares con $p < 0{,}001$ tras el ajuste. Las diferencias de mediana son de 14,66 puntos entre Bajo y Medio, 17,33 entre Medio y Alto y 31,99 entre Bajo y Alto, con intervalos bootstrap estrechos (tabla 4). El intervalo bootstrap del coeficiente de Pearson entre gaming y calificación ($[-0{,}573;\ -0{,}543]$) coincide con el clásico de Fisher al redondeo reportado, lo que da confianza en la estimación de incertidumbre.

En la regresión múltiple, con estudio, sueño, asistencia y uso no gaming constantes, una hora más de videojuegos se asocia con 5,23 puntos menos de calificación (IC bootstrap $[-5{,}30;\ -5{,}16]$), una hora más de estudio con 6,28 puntos más y una hora más de sueño con 3,75 puntos más. El modelo completo explica el 90,9 % de la varianza dentro de la muestra, aunque esa cifra describe el ajuste a los datos con los que se estimó y no mide la capacidad de predecir casos nuevos. El coeficiente de `uso_no_gaming` es prácticamente nulo ($\beta = 0{,}026$; p ajustado $= 0{,}599$), de modo que no hay evidencia de que ese tiempo se asocie por sí mismo con la calificación una vez considerados los otros hábitos. Los coeficientes estandarizados confirman el orden de magnitud: $-0{,}540$ para gaming, 0,722 para estudio, 0,241 para sueño y 0,144 para asistencia.

La interacción de H3 resultó estadísticamente detectable pero pequeña ($\eta_p^2 = 0{,}045$), frente a efectos principales grandes. La figura 5 muestra de dónde proviene. La brecha de calificación media entre el tercil de menos juego y el de más juego es de 31,7 puntos entre quienes estudian poco y de 32,3 puntos en el nivel medio de estudio, pero baja a 19,8 puntos entre quienes más estudian. En ese último grupo las

Tabla 4. Resultados principales de la Fase 2. Todos los valores p están ajustados por Benjamini-Hochberg dentro de su familia, salvo indicación. TE = tamaño del efecto.

Contraste	Estadístico	IC 95 % y TE	p ajust.
Correlaciones de Spearman con `grades`			
Videojuegos	$\rho_s = -0{,}547$	$[-0{,}563;\ -0{,}531]$	$< 0{,}001$
Estudio	$\rho_s = 0{,}742$	$[0{,}732;\ 0{,}751]$	$< 0{,}001$
Sueño	$\rho_s = 0{,}239$	$[0{,}218;\ 0{,}260]$	$< 0{,}001$
Asistencia	$\rho_s = 0{,}126$	$[0{,}104;\ 0{,}148]$	$< 0{,}001$
Terciles de gaming: Kruskal-Wallis y Dunn			
Global	$H(2) = 2.110{,}15$	$\varepsilon^2 = 0{,}264$	$< 0{,}001$
Bajo − Medio (mediana)	$z = 22{,}73$	14,66 [13,27; 16,29]	$< 0{,}001$
Bajo − Alto (mediana)	$z = 45{,}94$	31,99 [30,32; 33,72]	$< 0{,}001$
Medio − Alto (mediana)	$z = 23{,}21$	17,33 [15,58; 18,84]	$< 0{,}001$
Regresión múltiple ($R^2 = 0{,}909$; $F(5, 7994) = 16.006{,}39$)			
Videojuegos (puntos por hora)	$\beta = -5{,}230$	$[-5{,}296;\ -5{,}160]$	$< 0{,}001$
Estudio	$\beta = 6{,}279$	$[6{,}221;\ 6{,}336]$	$< 0{,}001$
Sueño	$\beta = 3{,}746$	$[3{,}644;\ 3{,}844]$	$< 0{,}001$
Asistencia	$\beta = 0{,}276$	$[0{,}263;\ 0{,}289]$	$< 0{,}001$
Uso no gaming	$\beta = 0{,}026$	$[-0{,}081;\ 0{,}119]$	0,599
Modelo factorial gaming × estudio (terciles)			
Gaming (ajustado por estudio)	$F(2, 7995) = 4.245{,}03$	$\eta_p^2 = 0{,}515$ [0,503; 0,527]	0,001*
Estudio (ajustado por gaming)	$F(2, 7995) = 7.676{,}54$	$\eta_p^2 = 0{,}658$ [0,648; 0,667]	0,001*
Interacción	$F(4, 7991) = 94{,}18$	$\eta_p^2 = 0{,}045$ [0,036; 0,054]	0,001*

* 0,001 es el mínimo que permite resolver la prueba con 999 permutaciones; no es un valor más preciso.

medias están cerca del tope de 100 (95,2 en el tercil de menos juego), de modo que el efecto techo puede estar comprimiendo parte de la diferencia, algo que el diseño no permite separar.

4.3 Alcance de las conclusiones

Las cuatro hipótesis encontraron respaldo estadístico. El único contraste sin evidencia fue el del coeficiente de `uso_no_gaming`, un predictor complementario que no formaba parte de ellas. Estas conclusiones describen asociaciones dentro del archivo. Un confusor plausible es el rendimiento previo, que podría influir a la vez en cuánto juega y cuánto estudia un estudiante y en sus calificaciones actuales; el contexto socioeconómico y la autorregulación podrían operar de modo semejante, y el archivo no contiene ninguna de esas variables. Además, la inferencia por permutación presupone intercambiabilidad bajo H_0, algo que no puede comprobarse con la información disponible, y los valores p tan pequeños se deben en buena parte al tamaño de la muestra, por lo que la lectura debe apoyarse en los tamaños de efecto y no en la significancia sola.

5 Fase 3: modelado predictivo

5.1 Diseño del experimento

La tarea es de regresión: estimar `grades` para estudiantes que no intervinieron en el ajuste del modelo. Los datos se dividieron en 80 % para entrenamiento (6.400 estudiantes) y 20 % para prueba (1.600), con semilla fija 42. Como el archivo no tiene componente temporal, una partición aleatoria es adecuada, aunque la ausencia de identificador impide descartar dependencia entre observaciones y la prueba podría

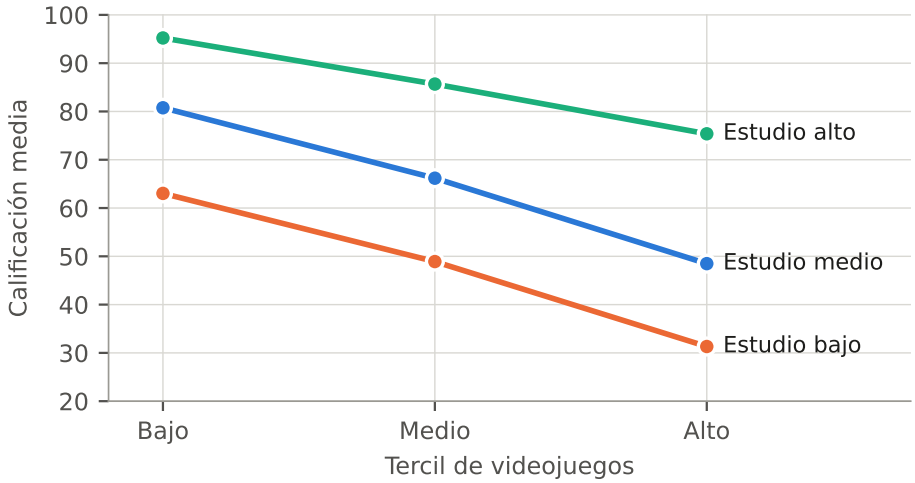


Figura 5. Calificación media por tercil de videojuegos, para cada tercil de horas de estudio (cada una de las nueve celdas tiene entre 865 y 908 estudiantes).

resultar algo optimista. Todas las decisiones de selección de variables, modelos e hiperparámetros se tomaron únicamente con el conjunto de entrenamiento y validación cruzada de cinco particiones (KFold con mezcla y semilla 42); el conjunto de prueba se usó una sola vez, al final.

Se fijó una línea base que predice siempre la media de las calificaciones de entrenamiento, y se compararon tres familias de modelos: regresión lineal, Random Forest y KNN. La regresión lineal y KNN incorporan un escalado estándar dentro de un pipeline, de modo que la media y la desviación se calculan solo con los datos de entrenamiento de cada partición. Los hiperparámetros se ajustaron con búsqueda en grilla sobre las mismas particiones. Para Random Forest la grilla combinó 200 o 300 árboles, profundidad máxima ilimitada, 10 o 20, y un mínimo de 1 o 3 observaciones por hoja; para KNN, 5, 11, 21 o 31 vecinos, ponderación uniforme o por distancia y distancia de Manhattan o euclídea. La configuración elegida fue 300 árboles, profundidad máxima 20 y mínimo de 3 observaciones por hoja para el bosque, y 21 vecinos con ponderación por distancia y distancia de Manhattan para KNN.

5.2 Selección de predictores

La Fase 2 había trabajado con cinco predictores: horas de juego, estudio, sueño, asistencia y `uso_no_gaming`. La primera versión de la Fase 3 cambió este último por `social_activity`, sin documentar el motivo ni comparar ambas opciones, y por ese motivo la versión revisada incorpora una comparación explícita. Se evaluaron tres conjuntos: el heredado de la Fase 2 con `uso_no_gaming`, el usado inicialmente en la Fase 3 con `social_activity` y uno que incluye ambos. La comparación se realizó únicamente sobre el conjunto de entrenamiento con validación cruzada de cinco particiones, y la prueba permaneció intacta.

Con Random Forest, el mejor modelo en los tres casos, el RMSE medio de validación fue 5,806 con `uso_no_gaming`, 5,819 con `social_activity` y 5,827 con ambas variables (figura 6). Con regresión lineal, los tres conjuntos son prácticamente indistinguibles (6,645 en los tres casos, con diferencias en el cuarto decimal). Se conservó el conjunto de la Fase 2 con `uso_no_gaming` por dos razones: obtuvo el menor RMSE promedio y mantiene la trazabilidad entre fases. La diferencia entre conjuntos es de unas pocas centésimas de punto, comparable con la variabilidad entre particiones (la desviación estándar del RMSE entre particiones es de 0,07 para Random Forest), de modo que no corresponde decir que `uso_no_gaming` sea claramente superior ni que `social_activity` sea inútil. Es una preferencia débil, específica de esta muestra, y la elección final se apoya sobre todo en la coherencia con la Fase 2.

5.3 Resultados en validación y en prueba

En validación cruzada, antes del ajuste de hiperparámetros, el RMSE de Random Forest fue 5,806, el de KNN 6,601, el de la regresión lineal 6,645 y el de la línea base 22,274. Tras la búsqueda en grilla, el

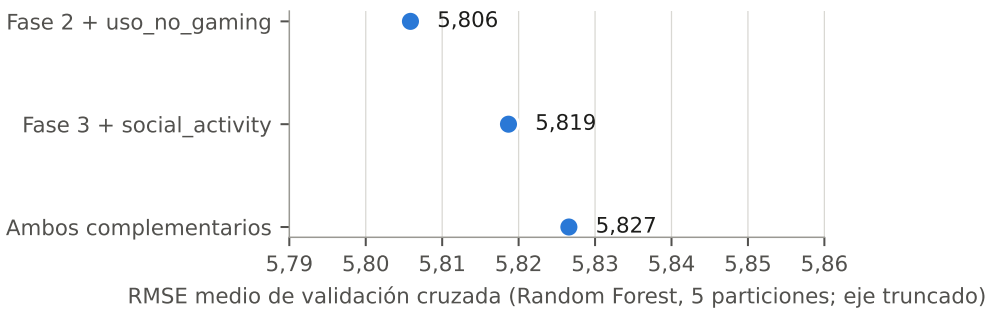


Figura 6. RMSE medio de validación cruzada del Random Forest según el conjunto de predictores, sobre el entrenamiento. El eje está truncado: las diferencias son de 0,01 a 0,02 puntos de nota.

Tabla 5. Desempeño en el conjunto de prueba ($n = 1.600$), evaluado una sola vez. La última columna es la reducción del RMSE respecto de la línea base.

Modelo	RMSE	MAE	MAPE (%)	R^2	Reducción
Línea base (media)	22,16	18,42	41,35	0,000	—
Regresión lineal	6,98	5,54	10,56	0,901	68,5 %
KNN	6,33	4,97	10,05	0,918	71,4 %
Random Forest	**6,00**	**4,61**	**8,96**	**0,927**	**72,9 %**

RMSE de validación bajó a 5,766 para Random Forest y a 6,184 para KNN; la regresión lineal no tiene hiperparámetros que ajustar. La tabla 5 muestra la evaluación final sobre los 1.600 estudiantes de prueba, con comparación explícita contra la línea base.

Random Forest fue el mejor modelo en las cuatro métricas. En promedio se aleja 4,61 puntos de la calificación real, explica el 92,7 % de la varianza de las calificaciones no vistas y reduce el RMSE de la línea base en 72,9 %. Los tres modelos superan ampliamente la línea base, lo que indica que los hábitos medidos contienen información predictiva real en este conjunto. La ventaja del bosque sobre la regresión lineal es de aproximadamente un punto de RMSE, lo que sugiere que la relación es en gran parte aditiva y lineal, y que el bosque captura una curvatura e interacciones menores, en línea con la interacción pequeña de la Fase 2.

5.4 Sobreajuste

La figura 7 compara el error en entrenamiento, validación y prueba. La regresión lineal tiene un error casi igual en los tres conjuntos (6,63, 6,64 y 6,98), de modo que no sobreajusta, aunque su flexibilidad es limitada. KNN con ponderación por distancia obtiene error cero en entrenamiento porque cada punto es su propio vecino más cercano; ese valor no mide calidad y presentarlo como desempeño sería engañoso, por lo que su error real se lee en validación (6,18) y prueba (6,33). Random Forest sobreajusta de forma moderada: su RMSE de entrenamiento es 3,21, casi la mitad del de validación (5,77). Lo importante para juzgar su generalización es la brecha entre validación y prueba, que es de 0,24 puntos (un 4 %), y que el error de prueba es algo mayor que el de validación, como corresponde a un modelo cuyos hiperparámetros se eligieron minimizando la validación. Dentro de este conjunto de datos, entonces, el bosque conserva su calidad con estudiantes nuevos; esa conclusión no garantiza lo mismo en otra población.

5.5 Análisis de errores

La figura 8 muestra los residuos del Random Forest en prueba. Se reparten alrededor de cero sin una curvatura marcada, y el 90 % de los casos tiene un error absoluto de hasta unos 10 puntos; solo el 5,6 % supera los 12 puntos. El rasgo más claro es el efecto techo: entre los 122 estudiantes de prueba con calificación 100, el modelo subestima en promedio 2,86 puntos, mientras que para el resto el residuo medio es $-0{,}25$. Como la nota real no puede exceder 100, los residuos cerca de ese valor quedan acotados y los

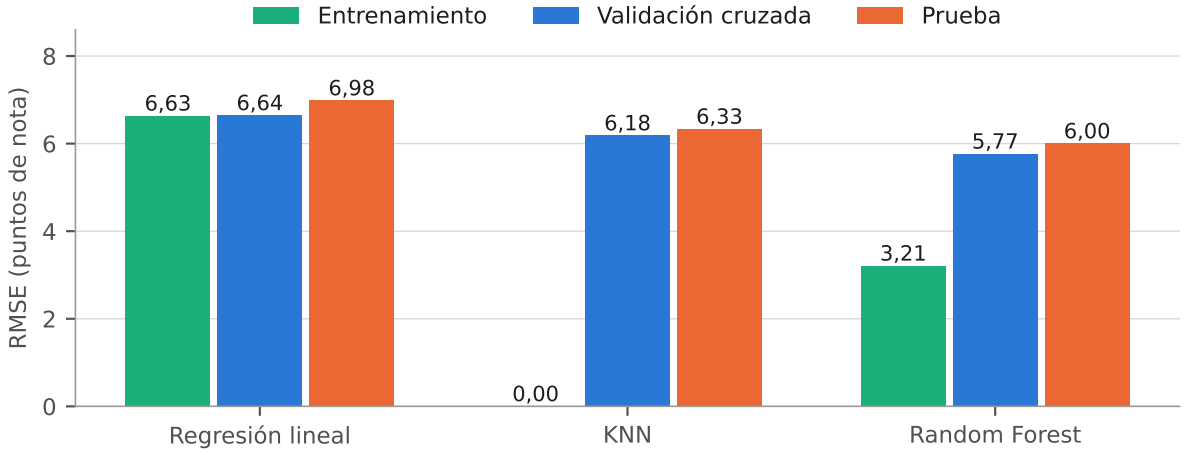


Figura 7. RMSE en entrenamiento, validación cruzada y prueba para cada modelo. El error nulo de KNN en entrenamiento es un artefacto del método y no refleja su calidad.

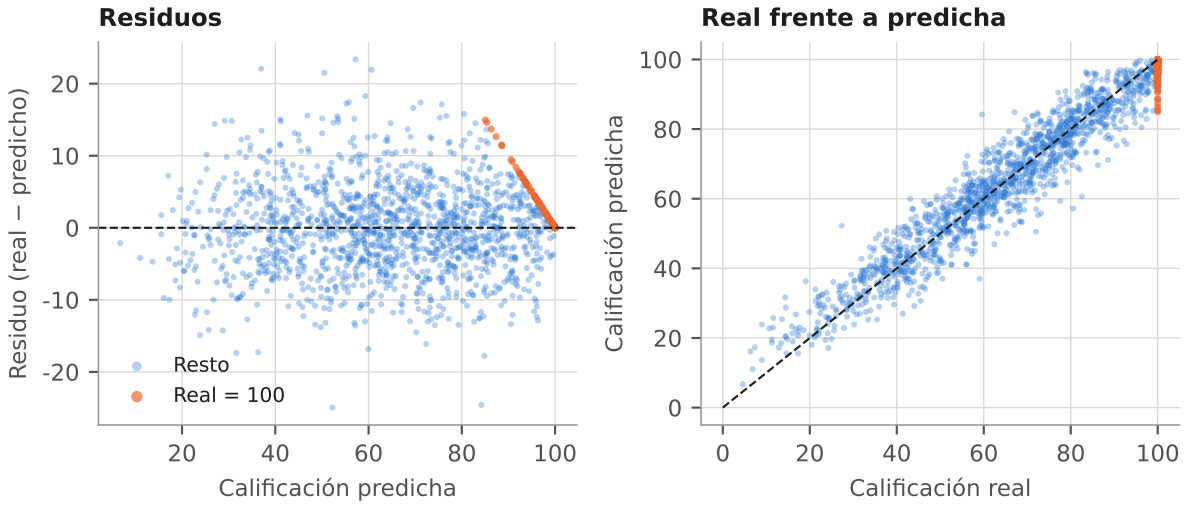


Figura 8. Random Forest en el conjunto de prueba. Izquierda: residuos frente a la predicción. Derecha: calificación real frente a la predicha; la línea discontinua es la predicción perfecta. En naranja, los estudiantes con calificación real igual a 100.

puntos forman una banda descendente. Además, un bosque promedia las calificaciones de estudiantes con hábitos parecidos y tiende a quedar por debajo del tope cuando ese grupo mezcla notas de 100 con notas apenas menores.

Los diez mayores errores absolutos van de 17,4 a 25,0 puntos, entre tres y cuatro veces el RMSE. El peor corresponde a un estudiante con poco juego (0,36 h), poco estudio (1,17 h) y sueño insuficiente (4,31 h), a quien el modelo asignó 52,3 puntos y cuya calificación fue 27,3. El segundo, con 1,87 h de juego, 5,24 h de estudio y 4,96 h de sueño, tuvo 59,6 frente a una predicción de 84,2. En sentido contrario, un estudiante con 4,26 h de juego, 3,78 h de estudio y 99,4 % de asistencia obtuvo 80,6 cuando se esperaba 57,2. Seis de los diez peores casos duermen 5,1 horas o menos, aunque esta condición ocurre en cerca del 23 % de la prueba, por lo que no hay base para afirmar un patrón. La explicación más plausible es que el modelo solo conoce cinco hábitos: el rendimiento previo, el contexto socioeconómico, la autorregulación y el ruido propio del proceso que generó los datos quedan fuera de lo que puede aprender.

5.6 Importancia de las variables

La importancia por permutación sobre el conjunto de prueba (10 repeticiones, criterio RMSE) mide cuánto empeora el error al desordenar cada variable (figura 9). Las horas de estudio lideran con un aumento

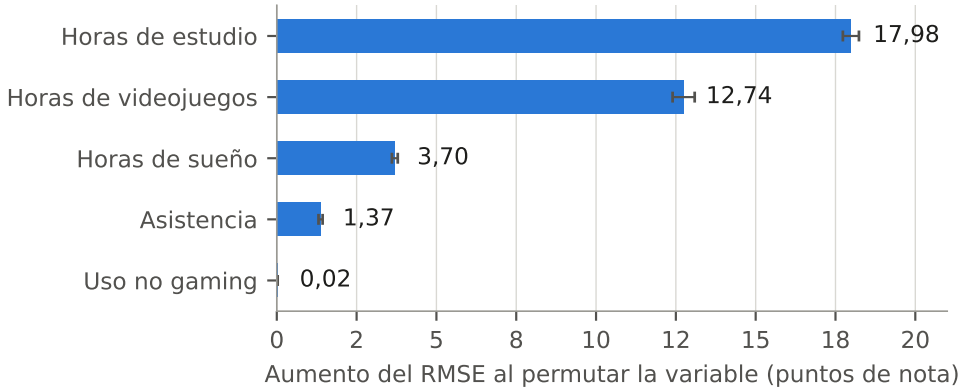


Figura 9. Importancia por permutación del Random Forest (aumento del RMSE al desordenar cada variable; barras de error: ± 1 desviación estándar).

Tabla 6. Convergencia de la evidencia por variable. Fase 1: correlación de Pearson con `grades`. Fase 2: correlación de Spearman y coeficiente de la regresión múltiple (puntos por hora o por punto porcentual). Fase 3: importancia por permutación (aumento del RMSE).

Variable	Fase 1 (r)	Fase 2 (ρ_s)	Fase 2 (β)	Fase 3 (imp.)
Horas de estudio	0,734	0,742	6,28	17,98
Horas de videojuegos	−0,558	−0,547	−5,23	12,74
Horas de sueño	0,245	0,239	3,75	3,70
Asistencia	0,130	0,126	0,28	1,37
Uso no gaming	0,007	—	0,03 ($p = 0{,}599$)	0,02

de 17,98 puntos de RMSE, seguidas por las horas de juego (12,74), el sueño (3,70) y la asistencia (1,37); `uso_no_gaming` aporta apenas 0,02. Este orden coincide con el de los coeficientes estandarizados de la Fase 2 y con el de las correlaciones de Spearman en valor absoluto, y que la variable sin asociación propia en la inferencia también carezca de aporte predictivo cierra una coincidencia entre las dos fases. La importancia por permutación expresa utilidad predictiva relativa, no causalidad. El riesgo de que se distorsione por correlación entre predictores es aquí bajo, porque las horas de juego, estudio y sueño y la asistencia casi no se correlacionan entre sí ($|\rho_s| \leq 0{,}031$), pero desordenar una variable siempre genera combinaciones poco realistas.

6 Integración de los hallazgos

Las tres fases se corroboran entre sí, y la tabla 6 lo muestra variable por variable. Las magnitudes de la exploración, los contrastes de la inferencia y la importancia en el modelo ordenan los hábitos de la misma manera: estudio, videojuegos, sueño, asistencia, y casi nada para el uso no gaming. Que los resultados se mantengan cuando cambia el método, de correlaciones a regresión, a prueba por terciles y a un modelo predictivo no lineal, vuelve poco probable que la asociación dependa de una técnica particular. No prueba, en cambio, que refleje un proceso real, porque todas las técnicas se aplican a los mismos datos.

La diferencia entre inferir y predecir explica un resultado que podría parecer contradictorio. En la Fase 2, el sueño y la asistencia muestran evidencia estadística clara de asociación con las calificaciones, pero su importancia predictiva es pequeña. No hay conflicto: una variable puede estar relacionada con la respuesta y aportar poca información adicional cuando el modelo ya cuenta con predictores más informativos. La inferencia pregunta si hay evidencia de una asociación y de qué tamaño; la predicción pregunta cuánto mejora la estimación de casos nuevos al añadir esa variable. Por eso los valores p de la Fase 2 no deben usarse para elegir predictores, y por eso en la Fase 3 la selección se resolvió con validación cruzada y no con la significancia.

Un detalle del archivo ayuda a leer la magnitud de la asociación del juego. Los hábitos casi no se correlacionan entre sí (por ejemplo, $\rho_s = -0{,}022$ entre horas de juego y de estudio), de modo que ajustar por estudio y sueño apenas modifica la asociación del gaming: su coeficiente estandarizado en la regresión ($-0{,}540$) es prácticamente la correlación simple de la Fase 1 ($-0{,}558$). En este conjunto, la asociación negativa del juego no se explica porque quienes juegan más estudien o duerman menos. Esto describe cómo está construido el archivo y no tiene por qué cumplirse en estudiantes reales, donde el tiempo de juego, el de estudio y el de sueño comparten un mismo presupuesto diario y es de esperar que se relacionen.

7 Limitaciones

La primera limitación es la población. Los datos corresponden a un grupo anonimizado de estudiantes universitarios de Estados Unidos del que no se conocen las universidades, las carreras ni toda la composición demográfica. No se puede suponer que los resultados representen a los estudiantes paraguayos: los hábitos de estudio y de uso del tiempo, la organización de la enseñanza, la carga horaria, el acceso a dispositivos y el peso social de los videojuegos pueden ser distintos, y esas diferencias podrían alterar tanto el tamaño como la dirección de las asociaciones. Tampoco se conocen las condiciones de muestreo ni la fecha de recolección, y hay indicios de que el archivo fue generado artificialmente, lo que en el mejor de los casos haría que los modelos aprendan las reglas del generador y no la conducta de estudiantes reales.

La segunda tiene que ver con el diseño. Hay una sola medición por estudiante, de modo que no se puede observar cambios ni determinar qué ocurre primero: quien rinde menos podría refugiarse más en los videojuegos, y quien rinde más podría tener también más tiempo y disposición para estudiar. Faltan variables que podrían explicar buena parte de las asociaciones, como el rendimiento previo, la motivación, el contexto socioeconómico o la calidad docente, y no se puede descartar la existencia de sesgos o de variables omitidas. La independencia entre observaciones no puede verificarse.

La tercera es la medición de la variable objetivo. La escala de `grades` no está documentada y se asumió de 0 a 100; el efecto techo, con 574 estudiantes en 100, limita la discriminación entre rendimientos altos y es el origen de los mayores errores sistemáticos del modelo. Por último, la evaluación predictiva se basa en una única partición de prueba con una sola semilla, y no se estimó cuánto varían las métricas entre particiones ni se validó el modelo con una población independiente. Por todo esto, el modelo debe considerarse exploratorio.

8 Ética, uso responsable y trabajo futuro

Un modelo que estima calificaciones a partir de hábitos invita a usos que los datos no respaldan. Si se utilizara para señalar estudiantes «en riesgo» por sus horas de juego, podría producir etiquetado y estigmatización, y las profecías autocumplidas serían un riesgo real. Aunque el modelo no usa variables demográficas, los hábitos pueden actuar como indicadores indirectos de condiciones socioeconómicas y penalizar a grupos desfavorecidos. Recopilar horas de juego o de sueño de estudiantes, además, plantea cuestiones de privacidad y consentimiento. Y presentar una predicción puntual sin su incertidumbre induce a una precisión falsa: con un error típico de unos 6 puntos y casos que se desvían más de 20, la predicción de un estudiante individual puede ser muy distinta de su calificación real.

Por esos motivos, el modelo puede emplearse como herramienta exploratoria, para estimar el rendimiento esperado de grupos y no de individuos, para generar hipótesis y como ejercicio metodológico, siempre con entradas dentro de los rangos observados y sabiendo que su sesgo es mayor cerca del tope de 100. No debe usarse para etiquetar, sancionar o tomar decisiones académicas individuales, como becas o promoción, ni para simular intervenciones del tipo «si reduce el juego, subirá su nota», ni para poblaciones distintas de la analizada. El script de inferencia del repositorio solo comprueba que estén presentes las columnas requeridas y no valida unidades ni rangos, de modo que esa verificación queda a cargo de quien lo use.

Como trabajo futuro, el paso más valioso sería repetir el estudio con datos locales de estudiantes de Paraguay, con una muestra y un procedimiento de recolección documentados. Convendría incorporar variables contextuales (rendimiento previo, situación socioeconómica, carga laboral y horaria, motivación) y mediciones repetidas a lo largo del tiempo, que permitirían analizar cambios dentro de una misma persona y acercarse a preguntas sobre dirección de la relación. En el plano metodológico, valdría estimar la variabilidad de las métricas con validación cruzada repetida o con varias particiones de prueba, comparar con modelos que traten explícitamente el techo de la escala y validar el modelo con una población independiente antes de cualquier uso real.

9 Conclusión general

La pregunta de la Fase 1 era en qué medida las horas diarias de videojuegos se asocian con el rendimiento académico de los estudiantes de 16 a 24 años del conjunto de datos, considerando también el estudio y el sueño. La respuesta que sostiene la evidencia reunida es que existe una asociación negativa, consistente entre métodos y de magnitud grande, que casi no cambia al descontar el estudio y el sueño. Entre las 8.000 observaciones, la correlación de Spearman entre horas de juego y calificaciones es $-0{,}547$, los estudiantes del tercil que más juega promedian 28,5 puntos menos que los del tercil que menos juega, y con estudio, sueño y asistencia constantes cada hora adicional de juego se asocia con unos 5,2 puntos menos. Las horas de estudio presentan una asociación positiva aún más fuerte ($\rho_s = 0{,}742$; unos 6,3 puntos más por hora), y el sueño y la asistencia aportan asociaciones positivas menores.

El proyecto mostró también que esa estructura permite predecir con un error acotado. El modelo Random Forest, con horas de juego, estudio, sueño, asistencia y uso no gaming, alcanzó en el conjunto de prueba un RMSE de 6,00, un MAE de 4,61 y un R^2 de 0,927, frente a un RMSE de 22,16 de la línea base, y su error en prueba (6,00) es consistente con el de validación (5,77). Las horas de estudio y de juego concentran su capacidad predictiva, y el orden de importancia coincide con el de las fases anteriores. El conjunto de predictores se decidió comparando alternativas sobre el entrenamiento, con una diferencia pequeña a favor de `uso_no_gaming` que se interpreta con cautela.

Estos resultados deben leerse con sus límites. Son asociaciones y capacidad predictiva dentro de un grupo anonimizado de estudiantes universitarios de Estados Unidos, de una sola medición, sin muestreo documentado y con señales de generación artificial; no permiten afirmar que jugar cause menores calificaciones ni que estudiar más produzca por sí mismo mejores resultados, y no pueden trasladarse directamente a estudiantes de Paraguay. Para validar estas conclusiones en el contexto local serían necesarios datos propios, una muestra documentada, variables contextuales y mediciones repetidas.

Declaración de uso de asistentes de inteligencia artificial

Se utilizó un asistente de inteligencia artificial como apoyo para consolidar y redactar este informe a partir de los informes de las tres fases y de los resultados guardados en el repositorio, para regenerar las figuras desde los datos y para contrastar las cifras con los archivos de resultados y con el notebook ejecutado de la Fase 3 revisada. No se le delegaron las decisiones metodológicas ni la interpretación de los resultados, que corresponden al equipo. Los integrantes asumen la responsabilidad de verificar y comprender todo el contenido de este informe, incluidos los cálculos y el código que lo respaldan.

Referencias

Adelantado-Renau, M., et al. (2019). Association between screen media use and academic performance among children and adolescents: a systematic review and meta-analysis. *JAMA Pediatrics*, 173(11), 1058–1067.

Alzahrani, S. y Griffiths, M. D. (2024). Problematic gaming and students' academic performance: a systematic review. *International Journal of Mental Health and Addiction*. https://doi.org/10.1007/s11469-024-01338-5

Benjamini, Y. y Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society, Series B*, 57(1), 289–300.

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.

Chapman, P., et al. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.

Drummond, A. y Sauer, J. D. (2014). Video-games do not negatively impact adolescent academic performance in science, mathematics or reading. *PLoS ONE*, 9(4), e87943.

Freedman, D. y Lane, D. (1983). A nonstochastic interpretation of reported significance levels. *Journal of Business & Economic Statistics*, 1(4), 292–298.

Gaming vs Academic Performance (s. f.). Conjunto de datos publicado en Kaggle por `aiexplorer77`.

Hastie, T., Tibshirani, R. y Friedman, J. (2009). *The Elements of Statistical Learning* (2.ª ed.). Springer.

Pedregosa, F., et al. (2011). Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.